

# Cegos por Zonas: Avaliando Robustez Visual, Permanência de Objeto e Propriocepção em Agentes de Aprendizado por Reforço Profundo via Oclusão Seletiva

---

## 1. A Definição do Problema (O "Porquê")

Agentes de DRL (Deep Reinforcement Learning) baseados em visão (como DQN e PPO) frequentemente sofrem de "overfitting visual". Eles não aprendem a física do jogo; eles aprendem a reagir a padrões de pixels específicos.

A proposta inova ao **decompor a tela do jogo em funções cognitivas distintas**. Ao aplicar a mancha (occlusão) em locais fixos, isolando variáveis específicas:

### A. Hipótese da Propriocepção (Zona Bottom)

- **O Conceito:** Propriocepção é a capacidade de um agente saber a posição e configuração do seu próprio "corpo" no espaço sem precisar olhar diretamente para ele.
- **O Teste (Zona Bottom):** Ao cobrir a área do *paddle*, removemos o feedback visual direto da ação do agente.
- **A Pergunta Científica:** "O agente DQN consegue inferir sua posição atual baseando-se apenas na memória de suas ações passadas (integração de caminho) ou ele depende exclusivamente da verificação visual frame-a-frame?"
- **Expectativa no Artigo:** Se o desempenho cair drasticamente, isso sugere que a arquitetura CNN padrão não desenvolve uma representação interna latente da posição do agente (self-localization), dependendo puramente de feedback visual reativo.

### B. Hipótese da Estimativa de Trajetória e Permanência de Objeto (Zona Middle)

- **O Conceito:** Permanência de Objeto é a compreensão de que objetos continuam existindo mesmo quando não são vistos. Estimativa de Trajetória exige calcular vetores de velocidade ( $v_x, v_y$ ) e prever  $P_{\text{futuro}} = P_{\text{atual}} + v \times t$ .
- **O Teste (Zona Middle):** A bola atravessa um "vazio" onde a física continua agindo, mas a observação é nula.
- **A Pergunta Científica:** "O empilhamento de frames (Frame Stacking,  $n=4$ ) fornece contexto temporal suficiente para que a rede neural 'alucine' a posição correta da bola durante a oclusão? Ou o agente trata a bola que entra na mancha como um objeto que desapareceu?"

- **Expectativa no Artigo:** Esta zona deve ser a mais letal para a sobrevivência imediata. Espera-se que o agente falhe em interceptar bolas rápidas ou em ângulos agudos, pois a "cegueira" no meio do caminho quebra a continuidade da inferência visual da CNN.

### C. Hipótese de Planejamento e Memória de Longo Prazo (Zona Top)

- **O Conceito:** Planejamento envolve tomar decisões que não trazem recompensa imediata (sobrevivência), mas maximizam o retorno futuro (limpar a fase). No Breakout, isso significa mirar em áreas com tijolos restantes.
- **O Teste (Zona Top):** O agente vê a bola e a si mesmo, mas não vê o alvo (os tijolos).
- **A Pergunta Científica:** "O agente consegue construir um mapa mental (World Model implícito) de onde os tijolos ainda existem, ou ele atira a bola aleatoriamente esperando acertar algo?"
- **Expectativa no Artigo:** Diferente das outras zonas, aqui o agente **não deve morrer** mais rápido (a sobrevivência está garantida). Porém, a métrica de **Eficiência (Pontos por Step)** deve cair. O agente vai demorar muito mais para terminar o jogo, jogando a bola em áreas vazias por não saber onde mirar.

---

## 2. Estruturando as Hipóteses Formais


Hipóteses a serem validadas pelos gráficos que vamos gerar:

**\$H\_1\$ (Fragilidade de Propriocepção):** A oclusão da zona do agente resultará em um comportamento de "segurança", onde o agente tende a ficar parado no centro ou nas bordas, reduzindo a exploração espacial para minimizar o erro de posição.

**\$H\_2\$ (Ruptura de Continuidade Temporal):** Na Zona Middle, a performance do agente terá uma correlação negativa direta com a velocidade da bola. Quanto mais rápida a bola (menos frames ela passa *antes* da mancha), pior será a predição da trajetória, evidenciando as limitações do *Frame Stacking* como memória de curto prazo.

**\$H\_3\$ (Ineficiência de Planejamento):** A oclusão da Zona Top não afetará significativamente a duração média do episódio (sobrevivência), mas reduzirá drasticamente a taxa de aquisição de recompensa (pontos/segundo), indicando que a política aprendida é reativa (evitar a morte) e não estratégica (maximizar pontos).

# 1. A Anomalia da "Supervisão Cega" (PPO vs. Zona Bottom)



O dado mais chocante aparece no gráfico **1. Curva de Aprendizado (PPO)** [Imagem: image\_dcb4bc.jpg].

- **O Fenômeno:** A linha **Vermelha (Zona Bottom)** termina o treinamento com uma recompensa média **superior** à linha **Azul (Normal/Limpo)**.
- **Interpretação:** Isso sugere que, para o PPO, *não ver o paddle* (o próprio corpo) resultou em uma política mais eficiente do que ver tudo.
  - Ao remover o feedback visual do paddle, o agente foi forçado a aprender uma correlação determinística perfeita entre a ação enviada e o movimento resultante, ignorando o ruído visual de ver o paddle se mexendo.
  - [cite\_start]Isso refuta parcialmente a expectativa de "fragilidade" durante o *treino*, mostrando que o PPO consegue desenvolver uma propriocepção latente robusta se forçado a isso desde o início.

## 2. Validação da \$H\_2\$: A Zona Middle é o "Inferno Cognitivo"

Em ambos os algoritmos (DQN e PPO), a linha **Verde (Zona Middle)** apresenta consistentemente o **pior desempenho de aprendizado** (base dos gráficos de Score).

- **Evidência:** O score da Zona Middle estagna cedo (~10 pontos no DQN, ~15 no PPO).

**Análise:** Isso valida fortemente a **Hipótese de Ruptura de Continuidade Temporal (\$H\_2\$)**. [cite\_start]Mesmo com *Frame Stacking* (\$S\_n=4\$), as redes neurais não conseguem aprender efetivamente a "alucinar" a posição da bola quando ela desaparece no meio da tela. [cite\_start]A perda de informação sobre o vetor de velocidade é crítica demais para ser compensada pelo aprendizado.

## 3. Validação da \$H\_3\$: O "Sobrevivente Cego" (Zona Top)

A análise da Zona Top (Linha **Laranja**) nos gráficos de Sobrevivência (Gráfico 2) oferece a confirmação perfeita da **Hipótese de Planejamento (\$H\_3\$)**.

- **No PPO (image\_dcb4bc.jpg):** A linha Laranja atinge o topo absoluto de sobrevivência (~600 frames), superando até o ambiente Normal.
- **O Contraste:** Apesar de sobreviverem mais tempo, eles pontuam menos que o Agente Normal (Gráfico 1).

**Conclusão:** O agente aprendeu a **não morrer** (o que é fácil, pois ele vê a bola chegando no paddle), mas falha em **maximizar a recompensa** porque não vê os tijolos. [cite\_start]Ele joga defensivamente, rebatendo a bola para o vazio, validando que a política se tornou puramente reativa e não estratégica.

#### 4. DQN vs. PPO: Diferenças de Estabilidade

- **DQN (image\_dcb49d.jpg):** Mantém uma hierarquia clara e estável. Normal > Bottom > Top > Middle. O DQN pareceu "sofrer" mais com as oclusões de forma proporcional à perda de informação.
- **PPO (image\_dcb4bc.jpg):** Mostra comportamento caótico. Note a queda drástica de FPS na Zona Top (Gráfico 3: 93 FPS vs 485 FPS no Normal).
  - *Por que a lentidão?* Como o PPO na Zona Top sobrevive por muito tempo (episódios longos) sem ganhar recompensas rápidas, o buffer de experiência demora a preencher com dados significativos ("sinal de treino diluído"), ou o agente entra em loops de rebatidas verticais infinitas que consomem tempo de processamento sem avançar o treino.

#### Resumo Conclusivo do Treinamento


Os gráficos provam que **é possível aprender a jogar cego**, mas o custo varia por função cognitiva:


**Propriocepção (Bottom):** Facilmente aprendível (especialmente pelo PPO), indicando que a visão do corpo é redundante se o modelo interno for bom.

**Planejamento (Top):** O agente aprende a sobreviver, mas torna-se ineficiente ("zumbi"), pois não consegue mapear o objetivo.

1. **Permanência de Objeto (Middle):** É a barreira intransponível. [cite\_start]A cegueira de trajetória impede o aprendizado eficaz, confirmando ser a falha cognitiva mais grave para arquiteturas CNN padrão.

#### 1. Análise de Performance (Score)





### 1.1. Validação da Hipótese de Propriocepção (\$H\_1\$)

A Zona Bottom (inferior) remove o feedback visual do paddle. A hipótese sugere que agentes padrão não possuem autolocalização interna e dependem da visão reativa.

- **Evidência nos Heatmaps:**
  - **DQN:** O "Agente Normal" no "Amb. Bot" obteve um score de **0.0** (comparado a 25.0 no ambiente normal).
  - **PPO:** O "Agente Normal" no "Amb. Bot" obteve um score de **0.8** (comparado a 14.3 no ambiente normal).

Análise:

A queda catastrófica (para zero ou próximo disso) confirma a \$H\_1\$. O agente "Normal", ao perder a visão do próprio "corpo", torna-se incapaz de jogar. Isso indica que a arquitetura CNN padrão não desenvolveu uma representação latente da sua posição, dependendo exclusivamente da verificação visual quadro a quadro.

Nota interessante: Os agentes treinados especificamente nesse ambiente ("Agente Bot") tiveram alto desempenho (18.8 PPO / 17.3 DQN), provando que é possível aprender propriocepção, mas o agente padrão não o faz espontaneamente.

### 1.2. Validação da Hipótese de Continuidade Temporal (\$H\_2\$)

A Zona Middle (meio) oculta a trajetória da bola. A hipótese é que isso quebra a inferência física e é "letal para a sobrevivência imediata", pois o *Frame Stacking* não é suficiente para "alucinar" a posição da bola.

- **Evidência nos Heatmaps:**
  - **DQN:** O "Agente Normal" no "Amb. Mid" caiu para **0.3**.
  - **PPO:** O "Agente Normal" no "Amb. Mid" caiu para **0.4**.

Análise:

Os resultados validam robustamente a \$H\_2\$. Esta foi, em média, a zona mais destrutiva para o PPO (pior que a zona Bottom). Isso confirma que a "cegueira no meio do caminho quebra a continuidade da inferência visual". O agente trata a bola que entra na mancha como um objeto que desapareceu, falhando na interceptação.

### 1.3. Validação da Hipótese de Planejamento (\$H\_3\$)

A Zona Top (superior) oculta os tijolos (alvos). A hipótese é que a sobrevivência (não morrer) se manteria, mas a "taxa de aquisição de recompensa" cairia drasticamente, pois o agente não sabe onde mirar.

- **Evidência nos Heatmaps (Métrica: Score):**
  - **DQN:** O "Agente Normal" no "Amb. Top" pontuou **0.3**.
  - **PPO:** O "Agente Normal" no "Amb. Top" pontuou **1.4**.

Análise:

Embora não tenhamos o gráfico de "duração do episódio" para confirmar se eles sobreviveram por muito tempo, os heatmaps de Score confirmam a parte da Ineficiência de Planejamento da \$H\_3\$.

- No PPO, a pontuação de 1.4 é marginalmente melhor que nas outras zonas ocluídas (0.8 e 0.4), sugerindo que ele consegue devolver a bola (sobrevive), mas não consegue pontuar efetivamente, validando que a política é reativa e não estratégica.
- O agente está "jogando a bola em áreas vazias por não saber onde mirar", resultando em pontuações abismais comparadas ao ambiente normal (14.3 e 25.0).

### Conclusão Geral das Imagens

As imagens corroboram fortemente as três hipóteses do artigo:

1. **DQN é mais frágil:** O agente DQN Normal falhou quase totalmente em todas as oclusões (0.0 a 0.3).
2. **Overfitting Visual Confirmado:** O fato de que os agentes "Especialistas" (diagonal da matriz: Agente Bot no Amb. Bot, etc.) conseguem pontuações altas (ex: 23.3 para PPO Top/Top) demonstra que a tarefa é solúvel. A falha dos agentes "Normais" prova que eles sofrem de "overfitting visual", aprendendo a reagir a pixels e não à física do jogo.

### 1. O "Paradoxo da Sobrevivência" (Análise Geral)



Nas imagens anteriores, vimos que o "Agente Normal" teve pontuação próxima de **0.0** nos ambientes ocluídos. Nestas novas imagens, vemos que esse mesmo agente atingiu a **sobrevivência máxima** (aprox. **26.998 steps**, o limite do ambiente) nesses mesmos cenários.

- **O que isso significa:** Em *Breakout*, para perder uma vida, a bola precisa passar pelo paddle. Para ganhar pontos, a bola precisa bater nos tijolos.
- **A Dedução:** Se o agente sobreviveu o tempo todo mas não pontuou, ele muito provavelmente **não iniciou o jogo** (não disparou a bola/ação "Fire") ou encontrou um estado cíclico onde a bola nunca desce.
- **Conclusão de Robustez:** A oclusão visual não fez o agente "jogar mal"; ela quebrou o gatilho de iniciação ou a capacidade do agente de reconhecer que o jogo precisa interagir. O agente "congelou".

## 2. Revalidação das Hipóteses com a Métrica de Tempo

### A. Hipótese da Propriocepção (\$H\_1\$ - Zona Bottom)

**Expectativa do PDF:** O agente adotaria um "comportamento de segurança" reduzindo a exploração.

- **Evidência (Sobrevivência):**



- **DQN Normal em Amb. Bot:** 26.998 steps (Máximo).
- **PPO Normal em Amb. Bot:** 26.998 steps (Máximo).
- **Análise:** A hipótese foi confirmada ao extremo. Ao não ver a si mesmo, o agente optou pela segurança total: a inação. Ele não arriscou mover o paddle ou iniciar a rodada, garantindo "sobrevivência" técnica, mas falhando na tarefa.

## B. Hipótese da Estimativa de Trajetória (\$H\_2\$ - Zona Middle)

**Expectativa do PDF:** Esta zona seria a "mais letal para a sobrevivência imediata", pois o agente falharia em interceptar a bola.

- **Evidência (Sobrevivência):**
  - **DQN Normal em Amb. Mid:** 26.998 steps (Máximo).
  - **PPO Normal em Amb. Mid:** 26.998 steps (Máximo).
- **Análise (Refutação Parcial/Nuance):** Aqui os dados parecem contradizer a expectativa de "morte rápida" do PDF. No entanto, a contradição é explicada pela paralisia. Se o agente tivesse jogado (lançado a bola), ele provavelmente teria morrido rápido (como sugerido pelo Score baixo). Como ele provavelmente não lançou a bola devido à confusão visual inicial, a "letalidade" da zona Mid não pôde ser testada na prática pelo agente Normal. Ele "desistiu" antes de morrer.

## C. Hipótese de Planejamento (\$H\_3\$ - Zona Top)

**Expectativa do PDF:** A sobrevivência estaria garantida, mas a eficiência cairia.

- **Evidência (Sobrevivência):**
  - **DQN Normal em Amb. Top:** 26.998 steps (Máximo).
  - **Score Anterior:** 0.3.
- **Análise:** Esta é a validação mais forte da \$H\_3\$. O agente de fato não morre (sobrevivência máxima confirmada). Diferente das outras zonas, aqui ele vê a bola e a si mesmo, então ele *poderia* jogar. O fato de ele sobreviver até o limite de tempo com score quase nulo indica que ele fica rebatendo a bola em um loop seguro ou, novamente, não inicia o jogo por não reconhecer os alvos (tijolos) como parte do estado motivador de recompensa.

---

## 3. Diferenças Críticas: DQN vs. PPO (Baseline)

Observando a coluna "Amb. Normal" (sem oclusão), percebemos uma diferença fundamental de "personalidade" entre os algoritmos:


| Métrica       | DQN (Agente Normal) | PPO (Agente Normal) | Interpretação                              |
|---------------|---------------------|---------------------|--------------------------------------------|
| Score         | 25.0 (Alto)         | 14.3 (Médio)        | DQN é mais agressivo/eficiente em pontuar. |
| Sobrevivência | 4.483 (Baixo)       | 20.631 (Alto)       | PPO prioriza a segurança/sobrevivência.    |


- **DQN:** É um jogador "Kamikaze eficiente". Ele aprendeu a pontuar muito rápido, mas morre cedo (4k steps).
- **PPO:** É um jogador "Sobrevivencialista". Ele joga por muito mais tempo (20k steps), mas acumula pontos mais lentamente.
- **Impacto da Oclusão:** Ironicamente, a oclusão igualou ambos. Ao remover a visão crítica, tanto o agressivo DQN quanto o cauteloso PPO reverteram para o estado passivo de "sobrevivência máxima por inação".

### Resumo Final

As imagens de sobrevivência comprovam que a **falha dos agentes não foi mecânica (errar a bola), mas cognitiva (falha na iniciação da tarefa)**. [cite\_start]A oclusão visual nas zonas críticas (Bottom/Mid/Top) é tão severa para a rede neural que o agente colapsa para um mínimo local de inatividade, validando a fragilidade das arquiteturas padrão de Deep RL mencionadas no documento.

Aqui está o resumo comparativo final, integrando a nova métrica de **Eficiência** (Pontos por Step/Tempo) com as análises anteriores de Score e Sobrevivência.





Esta métrica é o "sinal vital" definitivo: ela revela se o agente estava realmente jogando ou apenas existindo.

Tabela Comparativa de Resiliência: PPO vs. DQN

Esta tabela resume como cada algoritmo reagiu cognitivamente à cegueira seletiva.

| Característica                    | PPO (Proximal Policy Optimization)                                                                                  | DQN (Deep Q-Network)                                                                                          | Veredito da Oclusão                                                |
|-----------------------------------|---------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|
| Comportamento Base (Sem Cegueira) | <b>Sobrevivente Cauteloso.</b> Joga partidas longas (20k steps) com pontuação moderada. Baixa eficiência (0.1).     | <b>Pontuador Agressivo.</b> Joga partidas curtas (4k steps) com pontuação altíssima. Alta eficiência (0.6).   | O DQN é naturalmente mais eficiente em <i>Breakout</i> .           |
| Propriocepção (Zona Bottom)       | <b>Colapso por Inação.</b> Eficiência cai para <b>0.0</b> . Sobrevivência máxima (26k) indica que ele não se moveu. | <b>Colapso por Inação.</b> Eficiência cai para <b>0.0</b> . Sobrevivência máxima indica "medo" total de agir. | <b>Empate:</b> Ambos falham igualmente sem ver o paddle.           |
| Física/Trajetória (Zona Mid)      | <b>Colapso Total.</b> Eficiência <b>0.0</b> . O agente não consegue prever onde a bola vai estar após a mancha.     | <b>Colapso Total.</b> Eficiência <b>0.0</b> . A perda de continuidade visual impede qualquer jogada efetiva.  | <b>Empate:</b> A cegueira no meio do campo anula ambos os agentes. |
| Planejamento (Zona Top)           | <b>Ineficiência "Zumbi".</b> Eficiência <b>0.0</b> . Sobrevive, mas não pontua. Não sabe <i>onde</i>                | <b>Ineficiência "Zumbi".</b> Eficiência <b>0.0</b> . Sobrevive, mas vaga sem propósito.                       | <b>Empate:</b> Sem ver o alvo, ambos perdem o propósito do jogo.   |

| Característica                                  | PPO (Proximal Policy Optimization)                                                              | DQN (Deep Q-Network)                                                                           | Veredito da Oclusão                                                    |
|-------------------------------------------------|-------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|
|                                                 | mirar para ganhar recompensas.                                                                  |                                                                                                |                                                                        |
| <b>Adaptabilidade</b><br>(Treino Especializado) | <b>Alta.</b> O Agente treinado na Zona Bot recupera eficiência incrível (3.5) naquele ambiente. | <b>Moderada.</b> O Agente Bot recupera eficiência (1.2), mas inferior ao PPO no mesmo cenário. | <b>PPO vence:</b> Se treinado na cegueira, adapta-se melhor que o DQN. |

### Síntese Final do Experimento

A análise conjunta dos três conjuntos de dados (Score, Sobrevivência e Eficiência) valida robustamente as hipóteses do documento "Cegos por Zonas" e adiciona uma descoberta crucial sobre a natureza dessas redes neurais:

1. **Confirmação do "Overfitting Visual":** A eficiência de **0.0** dos Agentes Normais em todos os ambientes ocluídos prova definitivamente que **nenhum dos dois algoritmos aprendeu a física do jogo** (como "eu estou aqui", "a bola viaja assim"). Eles aprenderam apenas a mapear padrões visuais específicos (pixels) para ações. Quando os pixels mudam (oclusão), a "inteligência" desaparece.
2. **O Fenômeno da "Paralisia de Segurança":** A combinação de Sobrevivência Máxima com Eficiência Zero refuta a ideia de que os agentes jogaram mal e morreram. Pelo contrário, a cegueira ativou um **estado de falha passiva**: diante de um input visual desconhecido, a rede neural convergiu para a inação (não lançar a bola), o que paradoxalmente maximizou a duração do episódio sem gerar nenhuma recompensa.
3. **A Superioridade do PPO na Adaptação:** Embora o DQN seja melhor no jogo normal, os heatmaps de eficiência mostram que o **PPO é superior quando treinado sob restrições**. O "Agente Bot" do PPO atingiu uma eficiência de **3.5** no "Amb. Bot", superando qualquer outra métrica registrada, inclusive a do DQN no jogo normal (2.3). Isso sugere que o PPO é mais capaz de aprender representações latentes complexas (como propriocepção implícita) se forçado a isso durante o treino.